

Analyse SCENIC des régulons spécifiques par type cellulaire dans les carcinomes mammaires métaplasiques (MpBC)

Jordan Dutel

06 Juillet 2025

1 Introduction

Les carcinomes mammaires métaplasique (MpBC) sont caractérisés par une forte hétérogénéité phénotypique. L'identification des régulateurs transcriptionnels propres à chaque sous-types cellulaire est essentielle pour mieux comprendre leur biologie et à terme, proposer de nouvelles pistes thérapeutiques ciblées. Dans cet objectif, j'ai appliqué la méthodologie SCENIC (Single-Cell rEgulatory Network Inference and Clustering), via son implémentation Python "pyscenic", dans le but de reconstituer des réseaux de régulation transcriptionnelle à partir des profils d'expression des cellules issues des 15 échantillons MpBC disponibles.

2 Méthodologie

2.1 Préparation des données

Les matrices d'expression transcriptomique initiale (format .h5) par patiente ont d'abord été filtrées selon les standards recommandés par SCENIC. J'ai donc éliminé des matrices les spots exprimant moins de 200 gènes et les gènes exprimés dans moins de 3 spots (pyscenic tutorial). Cela a permis de supprimer les gènes trop faiblement exprimés et les spots peu informatifs éliminant donc le bruit contenu dans les données.

Par la suite, pour chaque type cellulaire, les spots correspondants ont été regroupés à travers les 15 échantillons pour constituer une matrice d'expression unique par type cellulaire. Pour cela, j'ai utilisé les barcodes associées à chaque spot et les annotations du type cellulaire réalisées par la pathologiste. J'avais à ma disposition plusieurs jeux d'annotation : une assez généraliste annotant les spots selon les grands sous-types retrouvés au sein des MpBC (par exemple "chondrosarcoma cells"), ou bien une plus détaillée, découpant parfois les sous-types en sous-catégories (par exemple "classical chondrosarcoma cells", "mucoid chondrosarcoma cells"). Pour cette analyse, j'ai donc choisi l'annotation détaillée des différents sous-types et les spots ne possédant aucune annotation ont été éliminés des matrices. De plus, la pipeline étant automatisée, il est rapide et facile de modifier le script effectuant cette préparation afin d'utiliser d'autres annotations.

Enfin, ces nouvelles matrices par type cellulaire ont été converties au format .loom, nécessaire pour l'entrée dans le pipeline pyscenic.

2.2 Pipeline SCENIC

La pipeline pyscenic se déroule en trois étapes successives :

1. Inférence du réseau de co-expression (Gene Regulatory Network, GRN)

Cette première étape permet d'identifier les facteurs de transcription co-exprimés avec leur gènes cibles et de reconstruire un réseau transcriptionnel propre à chacune des matrices d'expression fournit en entrée. Pour cela, SCENIC utilise des modèles Random Forest pour évaluer la contribution de chaque facteur de transcription à l'expression d'un gène donné (algorithme GENIE3 ou GRNBoost2). Cela aboutit à une matrice d'adjacence des interactions, où chaque facteurs de transcription est associés à une liste de gènes cibles potentielles co-exprimées.

2. Filtrage par enrichissement en motifs

Les interactions trouvées précédemment sont filtrés afin de ne conserver que celle qui sont les plus biologiquement plausibles. Pour cela, SCENIC utilise l'outil RcisTarget qui interroge des bases de données de motifs de liaisons de facteur de transcription. Pour chaque co-expression identifiés à l'étape précédente, si les gènes cibles associés au facteur de transcription présentent un enrichissement en motifs de liaison dans les régions régulatrices (c'est à dire les régions promotrices et enhancers), alors l'interaction est considéré comme plausible et conservé pour la suite de l'analyse, sinon elle est supprimé. Ainsi, les interactions validées sont définit comme des régulons.

3. Évaluation de l'activité des régulons par spot de cellule (AUCell)

Enfin, à l'aide d'une méthode AUCell (Area Under the Curve Cell), un score d'activité est calculé pour chaque régulons, dans chaque spot. Ce score permet d'estimer la dynamique d'activation transcriptionnelle au sein de chaque spot. Une dernière étape, bien que optionnelle, est la binarisation des scores AUCell en valeur "Actif/Inactif" pour chaque spot. Cette étape se déroule en dehors de la pipeline pyscenic, et se base sur la distribution de ses scores AUCell au sein du spot. Il repose sur la définition automatique d'un seuil par régulon en identifiant une inflexion dans la courbe de distribution des scores. Ainsi, un régulon sera considéré comme actif dans un spot si son score AUCell dépasse ce seuil.

2.3 Analyses post-SCENIC

2.3.1 Top régulons

Après binarisation des scores AUCell, chaque régulon est considéré comme actif (égal à 1) ou inactif (0) dans un spot donné. Sur cette base j'ai calculé pour chaque type cellulaire la proportion moyenne de spots dans lesquels chaque régulon est actif. Ce pourcentage d'activation reflète la fréquence d'activation d'un régulon dans un type cellulaire donné. En classant les régulons selon cette fréquence (par ordre décroissant), il est ainsi possible d'identifier les régulons les plus prévalents et donc potentiellement fonctionnellement pertinents au sein de chaque type cellulaire.

2.3.2 Analyse des termes GO

À partir des régulons actifs les plus représentatifs de chaque type cellulaire, j'ai réalisé une analyse fonctionnelle des gènes cibles des facteurs de transcription (TF) associés. Pour cela, la liste des gènes cibles aux facteur de transcription a été soumise à l'outil GOST de la plateforme g:Profiler afin d'identifier les enrichissements en termes GO.

3 Résultats

À partir de la matrice AUCell binarisée, nous avons calculé, pour chaque régulon, la proportion de spots dans lesquels il est actif au sein de chacun des principaux types cellulaires identifiés dans les MpBC. Le tableau ci-dessous (Table 1) présente, pour les 5 sous-types tumoraux classiquement retrouvés au sein des MpBC, les 5 régulons les plus fréquemment actifs, accompagnés du pourcentage de spots annotés dans lesquels ces régulons sont activés. Ces régulons peuvent être considérés comme les régulateurs dominants potentiels dans leur compartiment tumoral respectif.

Cell types	Regulons	Percent cells active (%)
Chondroid tumour cells	ZNF789(+)	66.7
	MLXIPL(+)	65.0
	EVX1(+)	61.5
	MIXL1(+)	59.2
	ZFP3(+)	57.2
Epithelial tumor cells	GFI1(+)	67.1
	ESRRA(+)	53.1
	RARG(+)	49.6
	HOXB8(+)	46.6
	SIX3(+)	46.6
Osteosarcomatoid tumour	HOXD4(+)	80.5
	IRF8(+)	78.4
	SIX5(+)	68.5
	BHLHE41(+)	64.8
	HSF2(+)	64.4
Spindle cell tumour	IRF7(+)	72.4
	IRF1(+)	69.2
	SPI1(+)	68.9
	ZNF426(+)	62.1
	ZNF37A(+)	62.0
Squamous cell tumour	NR5A2(+)	64.6
	MECP2(+)	63.9
	SETDB1(+)	63.0
	ATF5(+)	62.6
	IRF3(+)	61.3

FIGURE 1 – Top 5 active regulons per cell types

Ces régulons représentent des candidats majeurs pour la caractérisation des programmes transcriptionnels distinctifs des différents compartiments cellulaires au sein des MpBC. L'ensemble des résultats sont disponibles dans le dossier : `/mnt/datadisk/Jordan/Results/SCENIC/`

Outputs_per_CellType/Annotations_old/Post_SCENIC_outputs/Top_regulons_binarized/binarized_outputs/

Afin de mieux caractériser les fonctions biologiques des régulons identifiés comme spécifiques à certains types cellulaires, une analyse d'enrichissement en termes GO (Gene Ontology) a été réalisée à partir des gènes cibles validés de ces régulons.

À titre d'exemple, le régulon HOXD4, qui présente la plus forte fréquence d'activation dans les cellules ostéosarcomatoïdes, a été analysé plus en détail. En considérant ses gènes cibles comme ensemble d'intérêt, nous avons évalué leur enrichissement fonctionnel à l'aide des catégories GO, notamment dans l'ontologie "cellular component".



FIGURE 2 – Graphe d'enrichissement GO (composants cellulaires) pour les régulons du sous-type ostéosarcomatoïde. Les nœuds jaunes indiquent les termes significativement enrichis ($p < 0,05$)

L'analyse révèle que le terme "collagen-containing extracellular matrix" est le plus significativement enrichi parmi les gènes cibles de HOXD4. Ce résultat suggère un lien potentiel entre l'activation transcriptionnelle de HOXD4 et la modulation du microenvironnement extracellulaire.

4 Discussions et perspectives

L'analyse d'enrichissement en termes GO révèle que les régulons identifiés par notre pipeline pySCENIC sont associés à des réseaux de gènes pertinents pour caractériser les différents phénotypes cellulaires et présentent une cohérence biologique selon le sous-type tumoral considéré. Par exemple, le sous-type ostéosarcomatoïde est enrichi pour des termes GO liés à la production de matrice extracellulaire, ce qui correspond à sa caractérisation histologique par une abondante matrice osseuse. Ces résultats indiquent que notre approche permet de capturer des régulations transcriptionnelles spécifiques à chaque type cellulaire. Toutefois, une analyse plus approfondie sera nécessaire pour élucider les mécanismes précis qui orientent la différenciation d'une cellule tumorale vers un sous-type plutôt qu'un autre, et pour savoir s'il existe un ou des facteurs de transcription drivers.

De plus, les potentiels effet de batch inter-patient ne sont actuellement pas corrigés. Il se peut donc que les résultats obtenus soient influencés par l'origine du patient. Dans la suite des analyses il faudra donc ajouter en amont de cette pipeline une gestion des effets inter-patients afin de réduire ces biais-là.

Enfin, la pipeline SCENIC infère les réseaux de régulation sur la base de la co-expression de paires facteur de transcription/gène cibles, et de la présence de motifs dans les promoteurs, des gènes. Cependant, une validation expérimentale sera par la suite nécessaire pour confirmer le rôle effectif de ces régulons et afin d'avoir des preuves fonctionnelles directes.

5 Informations pratiques

Les résultats des 3 étapes de la pipeline pyscenic sont stockés dans `/mnt/datadisk/Jordan/Results/SCENIC/Outputs_per_CellType/Annotations_old/SCENIC_pipeline_outputs`

On y retrouve :

- Les fichiers `.loom` des matrices initiales filtrées ou non, spécifiques au type cellulaire XXX : `/mnt/datadisk/Jordan/Results/SCENIC/Outputs_per_CellType/Annotations_old/SCENIC_pipeline_outputs/XXX/Raw_matrix`
- La matrice d'adjacence de l'étape 1 de SCENIC : `/mnt/datadisk/Jordan/Results/SCENIC/Outputs_per_CellType/Annotations_old/SCENIC_pipeline_outputs/XXX/Expr_matrix_adj`
- La matrice des régulons de l'étape 2 de SCENIC : `/mnt/datadisk/Jordan/Results/SCENIC/Outputs_per_CellType/Annotations_old/SCENIC_pipeline_outputs/XXX/Regulons`
- La matrice AUCell de l'étape 3 de SCENIC : `/mnt/datadisk/Jordan/Results/SCENIC/Outputs_per_CellType/Annotations_old/SCENIC_pipeline_outputs/XXX/AUCELL`

Les résultats des analyses post-SCENIC répertoriant les régulons les plus importants par sous-types sont stockés dans `/mnt/datadisk/Jordan/Results/SCENIC/Outputs_per_CellType/Annotations_old/Post_SCENIC_outputs`. Le dossier `/Top_regulons_binarized` contient les matrices AUCell binarisées par sous-types et la liste triée des top régulons.

Les scripts permettant de générer ces résultats se situent dans le dossier `/mnt/datadisk/Jordan/Scripts/SCENIC/`. Le script bash utilisable sur le cluster et correspondant à la pipeline pyscenic correspond à `/mnt/datadisk/Jordan/Scripts/SCENIC/Job_pyscenic/Per_celltype/job_pyscenic_celltype.sh`. Il faut bien penser à garder les scripts python (`preprocess_to_loom.py` et `transpose3.py`) dans le même dossier que le script de la pipeline.

Enfin les scripts permettant de réaliser les analyses post-scenic (binarisation et liste des top régulons) sont localisés dans `/mnt/datadisk/Jordan/Scripts/SCENIC/Post_Scenic_analysis/Most_important_reg_CellType_SCENIC_binarization.py`